MODEL HYBRID SVAR-XGBOOST UNTUK PREDIKSI DAN ANALISIS KETERKAITAN DINAMIS KURS JPY/IDR DAN KRW/IDR PERIODE 2002–2026

Sanjiro Ozara Liu Tama
Program Studi Teknik Informatika, Fakultas Teknologi Informasi, Universitas Tarumanagara,
Jln. Letjen S. Parman No. 1, Jakarta, 11440, Indonesia
E-mail: sanjiro.825240074@stu.untar.ac.id

ABSTRAK

Prediksi nilai tukar merupakan salah satu aspek penting dalam analisis ekonomi dan keuangan karena fluktuasi kurs dapat memengaruhi aktivitas perdagangan dan investasi internasional. Penelitian ini mengusulkan model Hybrid SVAR-XGBoost untuk memprediksi kurs JPY/IDR dan KRW/IDR sekaligus menganalisis keterkaitan dinamis antara kedua mata uang tersebut. Dataset yang digunakan terdiri dari 6.260 observasi harian periode 2 Januari 2002 hingga 1 Januari 2026. Tahapan penelitian meliputi preprocessing data, pengujian stasioneritas menggunakan Augmented Dickey-Fuller (ADF), pemodelan Structural Vector Autoregression (SVAR), serta integrasi fitur fitted value dan structural shock ke dalam model XGBoost. Hasil penelitian menunjukkan bahwa model Hybrid SVAR-XGBoost menghasilkan nilai MAE, RMSE, MAPE, dan R^2 masing-masing sebesar 0,2222; 0,3041; 0,203%; dan 0,998857 untuk JPY/IDR, serta 0,0136; 0,0178; 0,116%; dan 0,998441 untuk KRW/IDR. Selain itu, hasil SVAR menunjukkan korelasi residual sebesar 0,3213 yang mengindikasikan adanya hubungan dinamis positif antara kedua kurs. Temuan penelitian menunjukkan bahwa integrasi informasi struktural dari SVAR mampu meningkatkan akurasi prediksi sekaligus memberikan pemahaman mengenai keterkaitan dinamis antara kurs JPY/IDR dan KRW/IDR.

Kata Kunci — nilai tukar, XGBoost, cross-currency feature engineering, Asian Currency Interaction Index, panel data

I. PENDAHULUAN

Nilai tukar merupakan salah satu indikator makroekonomi yang sensitif dan berdampak luas dalam perdagangan internasional, investasi lintas batas, manajemen risiko korporasi, serta pengambilan kebijakan fiskal dan moneter [1]. Fluktuasi kurs yang tajam menimbulkan ketidakpastian bagi pelaku usaha, investor, dan pemerintah. Dalam

konteks Indonesia, dua pasangan mata uang yang memiliki relevansi strategis adalah JPY/IDR dan KRW/IDR. Jepang dan Korea Selatan merupakan mitra dagang sekaligus sumber investasi langsung asing bagi Indonesia, sehingga dinamika kurs kedua mata uang tersebut terhadap Rupiah berdampak pada biaya impor, nilai ekspor, neraca pembayaran, dan keputusan keuangan perusahaan [2].

Penelitian prediksi nilai tukar secara historis banyak menggunakan model statistik seperti ARIMA, ARCH, dan GARCH [3]-[5]. Model tersebut mampu menangkap pola autoregresif dan volatilitas, tetapi sering menghadapi keterbatasan ketika data kurs menunjukkan hubungan non-linier, noise tinggi, dan perubahan rezim pasar. Pendekatan machine learning kemudian muncul sebagai alternatif yang lebih adaptif. Algoritma seperti Support Vector Machine, Random Forest, dan Long Short-Term Memory telah digunakan untuk mempelajari pola kompleks dalam data finansial [6]-[8]. Namun, banyak pendekatan masih memprediksi satu pasangan mata uang secara terpisah, sehingga potensi informasi lintas mata uang belum dimanfaatkan secara eksplisit.

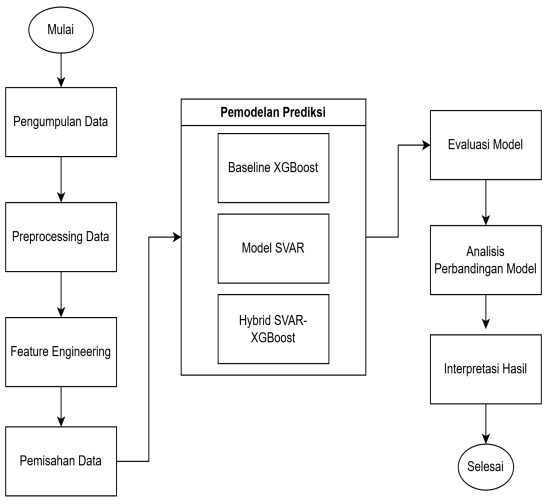
XGBoost (Extreme Gradient Boosting) yang diperkenalkan oleh Chen dan Guestrin [9] merupakan algoritma ensemble berbasis gradient boosting yang membangun pohon keputusan secara sekuensial dan menggunakan regularisasi untuk mengurangi overfitting. Keunggulan XGBoost terletak pada kemampuannya menangani relasi non-linier, fitur dalam jumlah besar, serta interaksi variabel yang kompleks [10]. Dalam konteks data keuangan, model berbasis machine learning dan boosting banyak digunakan karena mampu menangkap pola yang sulit direpresentasikan oleh model linear murni [11].

Kebaruan penelitian ini terletak pada pengembangan model Hybrid SVAR-XGBoost yang menggabungkan kemampuan SVAR dalam menangkap hubungan dinamis dan transmisi shock antar kurs dengan kemampuan XGBoost dalam memodelkan pola non-linear. Selain itu, fitur struktural hasil estimasi SVAR dimanfaatkan sebagai variabel prediktor tambahan pada XGBoost sehingga model tidak hanya menghasilkan prediksi yang lebih akurat, tetapi juga memberikan interpretasi mengenai keterkaitan dinamis antara kurs JPY/IDR dan KRW/IDR selama periode 2002–2026. Transformasi ini tidak dimaksudkan untuk mengklaim skala big data secara absolut, tetapi untuk memperkaya struktur observasi agar model dapat mempelajari pola lintas mata uang secara lebih sistematis [12]. Rumusan masalah dalam penelitian ini adalah: (1) bagaimana membangun model prediksi kurs JPY/IDR dan KRW/IDR menggunakan pendekatan Hybrid SVAR-XGBoost; (2) bagaimana hubungan dinamis antara kurs JPY/IDR dan KRW/IDR dapat diidentifikasi melalui model SVAR; (3) bagaimana pemanfaatan informasi struktural berupa fitted value dan structural shock hasil estimasi SVAR dapat meningkatkan kemampuan prediksi model XGBoost; (4) bagaimana performa model berdasarkan metrik MAE, RMSE, MAPE, sMAPE, dan R^2;

serta (5) bagaimana kinerja model Hybrid SVAR-XGBoost dibandingkan dengan model XGBoost tunggal dalam memprediksi kurs JPY/IDR dan KRW/IDR. Tujuan penelitian ini adalah membangun model prediksi kurs JPY/IDR dan KRW/IDR menggunakan pendekatan Hybrid SVAR-XGBoost, menganalisis keterkaitan dinamis antara kedua kurs melalui model SVAR, memanfaatkan fitur struktural hasil estimasi SVAR sebagai input tambahan pada model XGBoost, mengevaluasi performa model menggunakan metrik MAE, RMSE, MAPE, sMAPE, dan R^2, serta membandingkan kinerja model Hybrid SVAR-XGBoost dengan model XGBoost tunggal. Penelitian ini berkontribusi pada pengembangan metode prediksi kurs berbasis machine learning melalui integrasi Structural Vector Autoregression (SVAR) dan XGBoost. Kebaruan penelitian terletak pada pemanfaatan informasi struktural yang dihasilkan SVAR, berupa fitted value dan structural shock, sebagai fitur tambahan dalam model XGBoost untuk meningkatkan akurasi prediksi sekaligus menganalisis keterkaitan dinamis antara kurs JPY/IDR dan KRW/IDR selama periode 2002–2026. Hasil penelitian diharapkan dapat mendukung pengembangan sistem analitik keuangan berbasis data yang lebih informatif dan sejalan dengan tujuan SDG 8 dan SDG 9 [13].

II. METODE

Penelitian ini dirancang untuk memprediksi kurs JPY/IDR dan KRW/IDR sekaligus menganalisis keterkaitan dinamis antara kedua kurs tersebut. Data yang digunakan merupakan data sekunder berupa data historis kurs dari laman investing.com periode 2002–2026. Model yang digunakan dalam penelitian ini adalah Hybrid SVAR-XGBoost, yaitu gabungan antara Structural Vector Autoregression (SVAR) dan XGBoost. SVAR digunakan untuk menangkap hubungan dinamis dan struktural antara kurs JPY/IDR dan KRW/IDR, sedangkan XGBoost digunakan untuk mempelajari pola nonlinier dari data historis, fitur teknikal, lag harga, return, rolling volatility, serta output dari model SVAR. Tahapan penelitian dilakukan melalui beberapa proses, yaitu masukan data, preprocessing data, exploratory data analysis, feature engineering, uji stasioneritas, pembentukan model SVAR, pembentukan model XGBoost baseline dan Hybrid SVAR-XGBoost pembagian data latih dan data uji, serta evaluasi model. Alur tahapan penelitian dapat dilihat pada Gambar 1.



Gambar 1. Alur Tahapan Penelitian Prediksi dan Analisis Keterkaitan Dinamis Kurs JPY/IDR dan KRW/IDR

2.1. Pengumpulan Data

Dataset yang digunakan adalah kurs historis harian JPY/IDR dan KRW/IDR yang diperoleh dari file CSV historis Investing.com dan diolah menggunakan Python pada Google Colab. Data mencakup periode 2 Januari 2002 hingga 1 Januari 2026. Jumlah baris awal data JPY sebanyak 6.261, sedangkan data KRW sebanyak 6.260. Setelah inner join berdasarkan tanggal, diperoleh 6.260 baris data wide. Setelah feature engineering dan penghapusan nilai kosong akibat pembentukan lag serta rolling window, data wide menjadi 6.230 baris. Transformasi ke format panel/long menghasilkan 12.460 baris dengan 76 kolom karena setiap tanggal menghasilkan dua record, satu untuk JPY/IDR dan satu untuk KRW/IDR. Ringkasan dataset ditampilkan pada Tabel I.

TABEL I. Ringkasan Dataset

Keterangan	Nilai
Sumber data	File CSV historis dari Investing.com
Periode data	2 Januari 2002 - 1 Januari 2026
Jumlah baris awal JPY/IDR	6.261
Jumlah baris awal KRW/IDR	6.260
Baris setelah merge	6.260 baris wide
Baris setelah feature engineering	6.230 baris wide
Baris panel final	12.460 baris panel
Jumlah kolom panel	76 kolom
Kolom awal CSV	Tanggal, Close, Open, High, Low, ChangePct

2.2. Preprocessing Data

dalam proses prediksi. Tahapan ini meliputi konversi tanggal ke format datetime, pengurutan data berdasarkan waktu, perubahan format angka menjadi numerik, penghapusan kolom yang tidak relevan, serta penanganan nilai kosong pada variabel utama. Selanjutnya, kedua dataset digabungkan berdasarkan tanggal yang sama sehingga terbentuk dataset gabungan periode 2002–2026 yang digunakan dalam tahap analisis berikutnya.

2.3. Feature Engineering

Feature engineering dilakukan untuk menghasilkan fitur tambahan yang dapat meningkatkan kemampuan model dalam mempelajari pola data kurs. Fitur yang dibentuk meliputi lag harga, return harian, rolling mean, rolling standard deviation, rasio JPY/KRW, spread harga, return gap, high-low spread, dan open-close spread. Fitur-fitur tersebut digunakan untuk merepresentasikan pola historis, momentum, volatilitas, serta

hubungan pergerakan antara kurs JPY/IDR dan KRW/IDR dalam proses prediksi.

2.4. Pemisahan Data

Pemisahan data dilakukan dengan membagi dataset menjadi data latih dan data uji menggunakan rasio 80:20 berdasarkan urutan waktu. Data latih digunakan untuk melatih model Baseline XGBoost dan Hybrid SVAR-XGBoost, sedangkan data uji digunakan untuk mengevaluasi akurasi prediksi model. Pembagian data tidak dilakukan secara acak karena data kurs bersifat time series, sehingga urutan waktu perlu dipertahankan untuk mencegah data leakage.

2.5 Pemodelan Prediksi

Tahap pembuatan model dilakukan dengan membangun dua skenario prediksi, yaitu Baseline XGBoost dan Hybrid SVAR-XGBoost. Baseline XGBoost menggunakan fitur teknikal tanpa tambahan hasil SVAR, sedangkan Hybrid SVAR-XGBoost menggabungkan fitur teknikal dengan output SVAR berupa fitted value dan structural shock. Pemodelan ini bertujuan untuk memprediksi kurs JPY/IDR dan KRW/IDR sekaligus membandingkan performa model sebelum dan sesudah penambahan informasi hubungan dinamis antar kurs.

2.5.1 Baseline XGBoost

Model XGBoost ini digunakan sebagai pembanding untuk mengetahui kemampuan XGBoost dalam memprediksi kurs JPY/IDR dan KRW/IDR berdasarkan fitur teknikal dari data historis. Fitur yang digunakan pada skenario ini meliputi lag harga, return harian, rolling mean, rolling standard deviation, rasio JPY/KRW, spread harga, return gap, high-low spread, dan open-close spread.

XGBoost digunakan karena mampu memprediksi data kontinu dengan pendekatan ensemble dalam gradient tree boosting [14]. Algoritma ini membangun serangkaian pohon keputusan secara bertahap, di mana setiap pohon baru berupaya memperbaiki kesalahan prediksi dari pohon sebelumnya. Pada penelitian ini, fungsi loss yang digunakan adalah squared error karena target prediksi berupa nilai kurs. Fungsi loss tersebut dapat dituliskan dalam bentuk Mean Squared Error (MSE) pada Persamaan (1).

$$MSE = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2 \quad (1)$$

Keterangan :

n = jumlah data yang digunakan dalam pengujian model.

i = urutan data ke-i.

Σ = penjumlahan seluruh nilai kesalahan prediksi dari data pertama sampai data ke-n.

yi = nilai aktual kurs pada data ke-i.

ŷi = nilai prediksi kurs pada data ke-i.

Pada skenario Baseline XGBoost, MSE digunakan sebagai fungsi loss untuk menghitung kesalahan prediksi selama proses pelatihan model. Model ini menggunakan fitur

teknikal yang diperoleh dari data historis JPY/IDR dan KRW/IDR, seperti lag harga, return harian, rolling mean, rolling standard deviation, rasio JPY/KRW, spread harga, return gap, high-low spread, dan open-close spread.

2.5.2 Model SVAR

Structural Vector Autoregression (SVAR) digunakan untuk menangkap hubungan dinamis antarvariabel dalam data deret waktu. Pada penelitian ini, SVAR diterapkan pada return JPY/IDR dan return KRW/IDR agar hubungan pergerakan kedua kurs dapat dianalisis secara simultan. Model ini digunakan karena mampu menunjukkan pengaruh lag antarvariabel serta mengidentifikasi structural shock yang muncul dalam pergerakan kurs [15], [16].

$$A_0 Y_t = c + A_1 Y_{t-1} + A_2 Y_{t-2} + \cdots + A_p Y_{t-p} + \varepsilon_t \quad (2)$$

Yt = vektor variabel pada waktu ke-t. Dalam penelitian ini, Yt terdiri dari return JPY/IDR dan return KRW/IDR.

A0 = matriks hubungan struktural antarvariabel pada waktu yang sama.

c = konstanta dalam model.

Ai = matriks koefisien lag ke-i yang menunjukkan pengaruh variabel pada periode sebelumnya terhadap variabel saat ini.

Yt-i = nilai variabel pada periode sebelumnya atau lag ke-i.

p = panjang lag yang digunakan dalam model.

εt = structural shock atau kejutan struktural pada waktu ke-t.

Pada penelitian ini, hasil SVAR yang digunakan adalah fitted value dan structural shock dari return JPY/IDR dan return KRW/IDR. Fitted value menunjukkan nilai yang diperkirakan oleh model SVAR, sedangkan structural shock menunjukkan kejutan atau perubahan yang tidak dijelaskan oleh pola historis sebelumnya. Kedua output tersebut kemudian digunakan sebagai fitur tambahan pada model Hybrid SVAR-XGBoost.

2.5.3 Hybrid SVAR-XGBoost

Hybrid SVAR-XGBoost merupakan pendekatan pemodelan yang menggabungkan metode ekonometrika dan machine learning dalam satu proses prediksi. Model hybrid digunakan untuk memanfaatkan keunggulan masing-masing metode, yaitu SVAR dalam menangkap hubungan dinamis dan structural shock pada data deret waktu, serta XGBoost dalam mempelajari pola nonlinier dari fitur yang digunakan. Dengan penggabungan tersebut, output SVAR dapat dijadikan fitur tambahan pada XGBoost sehingga model tidak hanya bergantung pada pola historis, tetapi juga mempertimbangkan informasi struktural yang dihasilkan dari tahap sebelumnya. Pendekatan hybrid dipilih karena mampu mengombinasikan kelebihan dua model untuk menghasilkan prediksi yang lebih optimal dibandingkan penggunaan model tunggal [17].

$$\hat{y}_t = f_{XGB}(X_t^{tech}, F_t^{SVAR}, \varepsilon_t^{SVAR}) \quad (3)$$

Dimana, $\hat{y}t$ merupakan nilai prediksi kurs pada waktu ke-t, fXGB merupakan fungsi prediksi XGBoost, X^{tech} merupakan fitur teknikal, F_t^{SVAR} merupakan fitted value hasil SVAR, dan εt^{SVAR} merupakan structural shock hasil SVAR.

Pada penelitian ini, fitur teknikal yang digunakan meliputi lag harga, return harian, rolling mean, rolling standard deviation, rasio JPY/KRW, spread harga, return gap, high-low spread, dan open-close spread. Sementara itu, fitur tambahan dari SVAR terdiri dari JPY_VAR_Fitted, KRW_VAR_Fitted, JPY_VAR_Shock, dan KRW_VAR_Shock. Seluruh fitur tersebut digunakan sebagai input dalam XGBoost untuk memprediksi kurs JPY/IDR dan KRW/IDR.

Model Hybrid SVAR-XGBoost digunakan sebagai pembanding terhadap Baseline XGBoost. Perbandingan ini dilakukan untuk melihat apakah informasi fitted value dan structural shock dari SVAR mampu membantu XGBoost menghasilkan prediksi yang lebih baik.

2.6 Evaluasi Model

Evaluasi model dilakukan untuk mengukur performa prediksi dari Baseline XGBoost dan Hybrid SVAR-XGBoost. Metrik yang digunakan dalam penelitian ini meliputi MAE, RMSE, MAPE, sMAPE, dan R^2. Metrik tersebut digunakan untuk mengukur tingkat kesalahan prediksi, sedangkan R^2 digunakan untuk melihat kemampuan model dalam menjelaskan variasi data aktual.

2.6.1 Metrik Evaluasi

2.6.1 Metrik Evaluasi

Evaluasi model dilakukan menggunakan MAE, RMSE, MAPE, sMAPE, dan R^2. Metrik tersebut digunakan untuk mengukur tingkat kesalahan prediksi serta melihat kemampuan model dalam menjelaskan variasi data aktual.

a. Mean Absolute Error (MAE)

$$\text{MAE} = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i| \quad (4)$$

Dimana, MAE merupakan rata-rata kesalahan absolut, y_i merupakan nilai aktual pada data ke-i, $\hat{y}_i$ merupakan nilai prediksi pada data ke-i, dan n merupakan jumlah data. Semakin kecil nilai MAE, maka semakin kecil kesalahan prediksi yang dihasilkan model.

b. Root Mean Squared Error (RMSE)

$$\text{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2} \quad (5)$$

Dimana, RMSE merupakan akar dari rata-rata kuadrat kesalahan prediksi, y_i merupakan nilai aktual, $\hat{y}_i$ merupakan nilai prediksi, dan n merupakan jumlah data. RMSE digunakan untuk melihat besar kesalahan prediksi dalam satuan yang sama dengan data asli. Semakin kecil nilai RMSE, maka semakin baik performa model.

c. Mean Absolute Percentage Error (MAPE)

$$\text{MAPE} = \frac{1}{n}\sum_{i=1}^{n}\left|\frac{y_i - \hat{y}_i}{y_i}\right| \times 100\% \quad (6)$$

Dimana, MAPE merupakan rata-rata persentase kesalahan absolut, y_i merupakan nilai aktual, $\hat{y}_i$ merupakan nilai prediksi, dan n merupakan jumlah data. MAPE digunakan untuk melihat tingkat kesalahan prediksi dalam bentuk persentase. Semakin kecil nilai MAPE, maka semakin baik akurasi model.

d. Symmetric Mean Absolute Percentage Error (sMAPE)

$$\text{sMAPE} = \frac{1}{n}\sum_{i=1}^{n}\frac{|y_i - \hat{y}_i|}{(|y_i| + |\hat{y}_i|)/2} \times 100\% \quad (7)$$

Dimana, sMAPE merupakan metrik persentase error yang menggunakan rata-rata nilai absolut aktual dan prediksi sebagai pembagi. y_i merupakan nilai aktual, $\hat{y}_i$ merupakan nilai prediksi, dan n merupakan jumlah data. sMAPE digunakan sebagai pembanding MAPE agar penilaian error lebih seimbang antara nilai aktual dan nilai prediksi.

e. Coefficient of Determination (R^2)

$$R^2 = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2} \quad (8)$$

Dimana, R^2 merupakan koefisien determinasi, y_i merupakan nilai aktual, $\hat{y}_i$ merupakan nilai prediksi, $\bar{y}$ merupakan rata-rata nilai aktual, dan n merupakan jumlah data. R^2 digunakan untuk melihat kemampuan model dalam menjelaskan variasi data aktual. Nilai R^2 yang semakin mendekati 1 menunjukkan bahwa model memiliki performa yang semakin baik.

2.6.2 Kriteria Perbandingan Model

Model terbaik ditentukan berdasarkan nilai MAE, RMSE, MAPE, dan sMAPE yang paling rendah, serta nilai R^2 yang paling tinggi. Perbandingan dilakukan antara Baseline XGBoost dan Hybrid SVAR-XGBoost pada masing-masing target prediksi. Jika model Hybrid SVAR-XGBoost menghasilkan error yang lebih rendah dan R^2 yang lebih tinggi, maka penambahan fitur SVAR dianggap mampu meningkatkan performa prediksi.

III. HASIL DAN PEMBAHASAN

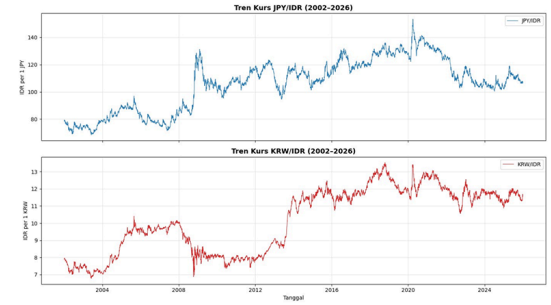
Bab ini menyajikan hasil eksplorasi data, proses pemodelan, evaluasi kinerja model, serta perbandingan performa antara model XGBoost dan Hybrid SVAR-XGBoost dalam memprediksi kurs JPY/IDR dan KRW/IDR. Pembahasan difokuskan pada analisis keterkaitan dinamis kedua kurs serta pengaruh integrasi informasi struktural dari SVAR terhadap akurasi prediksi.

3.1 EDA dan Preprocessing Data

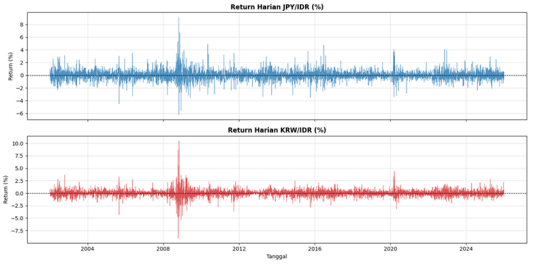
Tahap eksplorasi data dilakukan untuk memahami karakteristik kurs JPY/IDR dan KRW/IDR selama periode pengamatan.

Analisis meliputi identifikasi pola tren, return, volatilitas, korelasi antar variabel, serta pengujian stasioneritas sebagai prasyarat pemodelan VAR/SVAR.

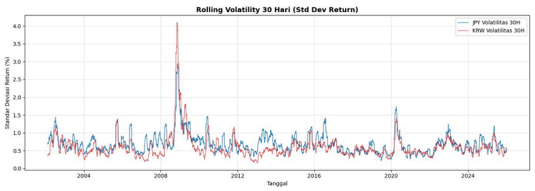
Keterangan	Nilai
Periode Data	2002–2026
Jumlah Observasi Awal	6.260
Jumlah Observasi Setelah Preprocessing	6.229
Variabel Utama	JPY/IDR, KRW/IDR



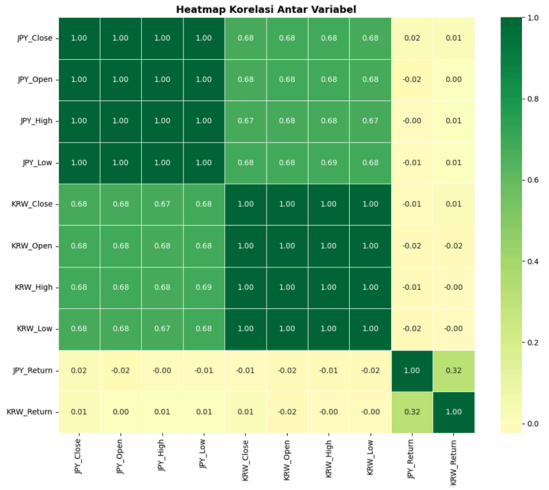
Berdasarkan Gambar 1 terlihat bahwa kurs JPY/IDR dan KRW/IDR mengalami fluktuasi sepanjang periode pengamatan. Secara umum kedua kurs menunjukkan kecenderungan bergerak searah pada beberapa periode tertentu, yang mengindikasikan adanya hubungan dinamis antar kedua mata uang Asia Timur tersebut.



Return harian menunjukkan volatilitas yang lebih tinggi dibandingkan harga kurs. Nilai return berfluktuasi di sekitar nol yang mengindikasikan karakteristik umum data keuangan.



Terdapat beberapa periode dengan lonjakan volatilitas yang cukup tinggi, menandakan adanya shock pasar yang memengaruhi kedua kurs.



Berdasarkan hasil ADF, data harga kurs tidak stasioner pada level, sedangkan data return telah stasioner sehingga digunakan dalam pemodelan VAR/SVAR.

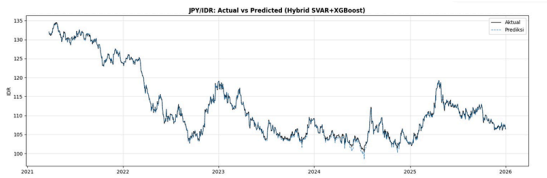
3.2 Hasil Pemodelan

Setelah data dinyatakan memenuhi kebutuhan analisis, dilakukan pemodelan menggunakan pendekatan VAR/SVAR untuk menangkap hubungan dinamis antar kurs. Informasi yang dihasilkan dari model tersebut kemudian digunakan sebagai fitur tambahan pada model Hybrid SVAR-XGBoost.

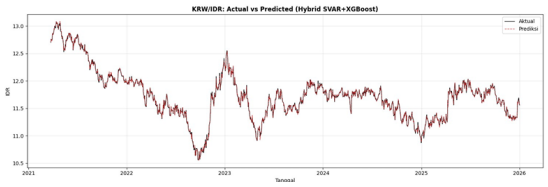
Parameter	Nilai

Lag Optimal (AIC)	**7**
Korelasi Residual	**3.213**

Lag optimal yang diperoleh berdasarkan kriteria AIC adalah 7. Nilai korelasi residual sebesar 0,3213 menunjukkan adanya hubungan dinamis positif antara return JPY/IDR dan KRW/IDR.



Kurva prediksi model Hybrid SVAR-XGBoost mampu mengikuti pola aktual JPY/IDR dengan cukup baik.



Hasil prediksi KRW/IDR menunjukkan kedekatan yang tinggi antara nilai aktual dan nilai prediksi.

3.3 Evaluasi Kinerja Model

Evaluasi dilakukan untuk mengukur kemampuan model dalam memprediksi nilai kurs menggunakan metrik MAE, RMSE, MAPE, dan koefisien determinasi (R^2). Hasil evaluasi digunakan untuk membandingkan performa model XGBoost tunggal dengan model Hybrid SVAR-XGBoost.

Mata Uang	**Model**	**MAE**	**RMSE**	**MAPE**	**R^2**
JPY	XGBoost	2.269	3.114	207%	998.80
					2
JPY	Hybrid	2.222	3.041	203%	998.857
KRW	XGBoost	147	194	126%	998.151
KRW	Hybrid	136	178	116%	998.441

Model Hybrid SVAR-XGBoost menghasilkan nilai MAE, RMSE, dan MAPE yang lebih rendah dibandingkan model XGBoost tunggal. Peningkatan performa juga terlihat dari nilai R^2 yang lebih tinggi pada kedua kurs, menunjukkan bahwa informasi shock dan hubungan dinamis yang diekstraksi oleh SVAR mampu meningkatkan kemampuan prediksi XGBoost.

3.4 Perbandingan Model Terbaik

Mata Uang	**Penurunan RMSE**	**Peningkatan R^2**
JPY/IDR	2,34%	0,01%
KRW/IDR	8,25%	0,03%

Berdasarkan Tabel 5, model Hybrid SVAR-XGBoost mampu meningkatkan performa prediksi pada kedua mata uang dibandingkan model XGBoost tunggal. Pada kurs JPY/IDR, penggunaan informasi shock dan fitted value dari SVAR berhasil menurunkan nilai RMSE sebesar 2,34% dan meningkatkan nilai koefisien determinasi (R^2) sebesar 0,0055%. Sementara itu, pada kurs KRW/IDR, peningkatan performa terlihat lebih signifikan dengan penurunan RMSE sebesar 8,25% dan peningkatan R^2 sebesar 0,0291%.

Hasil tersebut menunjukkan bahwa informasi keterkaitan dinamis yang diperoleh dari model

SVAR mampu memberikan tambahan informasi yang relevan bagi XGBoost dalam mempelajari pola pergerakan kurs. Dampak peningkatan performa lebih besar pada KRW/IDR mengindikasikan bahwa kurs KRW/IDR memiliki hubungan yang lebih kuat terhadap informasi shock yang diekstraksi dari sistem multivariat dibandingkan JPY/IDR. Dengan demikian, pendekatan hybrid terbukti lebih efektif dibandingkan model tunggal dalam menghasilkan prediksi kurs yang akurat.

REFERENSI

[1] F. Nucera, L. Sarno, and G. Zinna, "Currency Risk Premiums Redux," *The Review of Financial Studies*, vol. 37, no. 2, pp. 356–408, 2024, doi: 10.1093/rfs/hhad049.

[2] Indonesia Trade Data, "Indonesia's Biggest Trade Partners: Key Trade Relationships," *Indonesia Trade Data*, Oct. 22, 2024. [Online]. Available: https://www.indonesiatradedata.com/blogs/indonesia-biggest-trade-partners

[3] P. Escudero, W. Alcocer, and J. Paredes, "Recurrent Neural Networks and ARIMA Models for Euro/Dollar Exchange Rate Forecasting," *Applied Sciences*, vol. 11, no. 12, Art. no. 5658, Jun. 2021, doi: 10.3390/app11125658.

[4] S. H. Raheem, F. H. H. Alhusseini, and T. Alshaybawee, "Modelling Volatility in Financial Time Series Using ARCH Models," *International Journal of Innovation, Creativity and Change*, vol. 12, no. 7, pp. 248–261, 2020.

[5] M. Epaphra, "Modeling Exchange Rate Volatility: Application of the GARCH and EGARCH Models," *Journal of Mathematical Finance*, vol. 7, pp. 121–143, Feb. 2017, doi: 10.4236/jmf.2017.71007.

[6] D.-Z. Cao, S.-L. Pang, and Y.-H. Bai, "Forecasting exchange rate using support vector machines," in *Proc. 2005 International Conference on Machine Learning and Cybernetics*, Guangzhou, China, 2005, vol. 6, pp. 3448–3452, doi: 10.1109/ICMLC.2005.1527538.

[7] A. Dingli and K. S. Fournier, "Financial Time Series Forecasting – A Machine Learning Approach," *Machine Learning and Applications: An International Journal*, vol. 4, no. 1/2/3, pp. 11–27, Sep. 2017, doi: 10.5121/mlaij.2017.4302.

[8] W. Cao, W. Zhu, W. Wang, Y. Demazeau, and C. Zhang, "A Deep Coupled LSTM Approach for USD/CNY Exchange Rate Forecasting," *IEEE Intelligent Systems*, vol. 35, no. 2, pp. 43–53, Mar./Apr. 2020, doi: 10.1109/MIS.2020.2977283.

[9] T. Chen and C. Guestrin, "XGBoost: A Scalable Tree Boosting System," in *Proc. 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD '16)*, San Francisco, CA, USA, 2016, pp. 785–794, doi: 10.1145/2939672.2939785.

[10] M. S. A. Dolon, "Hybrid machine learning–driven financial forecasting models: Integrating LSTM, Prophet, and XGBoost for enhanced stock price and risk prediction," *Review of Applied Science and Technology*, vol. 4, no. 1, pp. 1–34, 2025, doi: 10.63125/nr1j8527.

[11] B. Krollner, B. Vanstone, and G. Finnie, "Financial time series forecasting with

machine learning techniques: A survey," in *Proc. 18th European Symposium on Artificial Neural Networks (ESANN 2010): Computational Intelligence and Machine Learning*, Bruges, Belgium, Apr. 2010, pp. 25–30.

[12] Y. Mai, H. Chen, J.-Z. Zou, and S.-P. Li, "Currency co-movement and network correlation structure of foreign exchange market," *Physica A: Statistical Mechanics and its Applications*, vol. 492, pp. 65–74, Feb. 2018, doi: 10.1016/j.physa.2017.09.068.

[13] United Nations, "The Sustainable Development Goals Report 2023," United Nations, New York, 2023. [Online]. Available: https://unstats.un.org/sdgs/report/2023/

[14] F. Z. Ulya, S. Khomsah, and N. A. F. Tanjung, "Perbandingan algoritma XGBoost dan LSTM untuk memprediksi harga Bitcoin berdasarkan harga harian, sentimen, dan Google Trends Index," Jurnal Teknologi Informasi dan Ilmu Komputer, vol. 12, no. 6, pp. 1271–1280, 2025.

[15] C. A. Sims, "Macroeconomics and reality," Econometrica, vol. 48, no. 1, pp. 1–48, 1980.

[16] L. Kilian and H. Lütkepohl, Structural Vector Autoregressive Analysis. Cambridge: Cambridge University Press, 2017.

[17] Kevin, R. J. Iskandar, and S. Tendean, "Model Hybrid LSTM-XGBoost untuk Prediksi Nilai Tukar Rupiah terhadap Dolar Amerika," Universitas Widya Dharma Pontianak, 2025.